

CS285 HW3: DQN 与 SAC 实验报告

所有正式实验使用训练 seed 1，在本机 GPU 上运行。图中的横轴是环境步数；评估回报是每次评估 10 个回合的平均值。除明确标出的训练回报外，曲线均为未经平滑的评估均值。每个设置只有一次训练，因此比较只描述这些观测结果。

2.4 DQN: CartPole-v1

使用 ϵ -greedy 采样、经验回放和目标网络训练 DQN。评估平均回报在 95,000 步达到 500，满足调试目标。曲线在达到 500 后仍有波动，说明单个高分检查点并不代表此后每次评估都保持满分。




图 1. CartPole 的评估平均回报。

2.5 Double DQN: LunarLander 与 MsPacman

Double DQN 使用在线网络选择下一步动作，使用目标网络评价该动作。LunarLander 的最高评估平均回报为 280.34（450,000 步），首次达到 200 分是在 170,000 步。MsPacman 的最高评估平均回报为 2113（860,000 步），首次达到 1500 分是在 550,000 步；两项均达到作业目标。




图 2. LunarLander 的评估平均回报。





图 3. MsPacman 的训练与评估回报。

MsPacman 训练曲线按每 10,000 个环境步结束的回合分组，再对组内回报求平均。训练时执行带探索的 ϵ -greedy 策略，尤其早期 ϵ 较大；评估使用 $\epsilon=0$ 的贪心策略，并在检查点上单独运行 10 个回合。因此早期训练回报通常明显低于评估回报。两条曲线还采用不同的采样和聚合口径，不能当作同一组回合的成对结果比较。

2.6 LunarLander：学习率敏感性

选择学习率，因为它直接影响 Adam 更新幅度，可能改变 Q-learning 的学习速度和稳定性。以默认的 $1e-3$ 为基线，另外比较 $1e-4$ 、 $3e-4$ 和 $3e-3$ ；其余配置相同，均训练 500,000 步，每 10,000 步评估一次。



Learning rate was selected because it controls the scale of Adam updates and allows us to compare learning speed and stability of bootstrapped Q-learning. We compare the default 1e-3 with 1e-4, 3e-4, and 3e-3, keeping other training settings unchanged. Each run uses --seed 1 and 500,000 steps; each point averages 10 greedy evaluation episodes. Curves are unsmoothed. The shaded region marks the last 10 logged evaluations (400,000-490,000 steps). This is a single-run comparison per setting, not an average over training seeds.

图 4. 四个学习率的评估平均回报；浅灰区为最后 10 次评估。

学习率	首次 ≥ 200 的步数	最高评估均值	最后 10 次均值	最后 10 次标准差
1e-4	380,000	266.15	244.22	12.43
3e-4	190,000	257.92	234.30	21.67
1e-3	170,000	280.34	223.32	38.65
3e-3	260,000	255.37	167.19	56.59

默认学习率最快达到 200，峰值也最高；1e-4 达标最慢，但后期均值最高且波动最小。3e-4 在速度与后期表现之间折中；3e-3 的后期表现最差。表中的标准差是最后 10 个评估检查点之间的波动，不是跨训练 seed 的误差。

3.4 SAC：HalfCheetah 固定温度

固定温度 $\alpha=0.1$ 的 SAC 在 265,000 步首次超过 6000，最高评估平均回报为 9664.60（910,000 步）。最后 10 次评估的均值为 9412.11，满足作业要求。




图 5. HalfCheetah 固定温度 SAC 的评估平均回报。

3.5 SAC：自动温度

自动调温版本在 225,000 步首次超过 6000，最高评估平均回报为 9346.23；固定温度版本的峰值为 9664.60。两者都达到目标，自动调温在本次单 seed 实验中没有超过已经调好的固定温度基线。最后 10 次评估的均值分别为 9219.50 和 9412.11。




图 6. 上：固定与自动温度的评估回报；下：自动学习的温度 α 。

自动温度从 0.1 开始，约在 31,000 步降至 0.020，随后逐渐上升，末期约为 0.124。这与训练早期策略熵相对充足、调温器降低探索权重，随后策略趋于集中、调温器提高权重以维持目标熵的解释一致；温度轨迹本身不能单独证明这一原因。

3.6 Hopper: 单 Q 与 clipped double-Q

单 Q 的最高评估平均回报为 833.40，未达到 1500。Clipped double-Q 在 190,000 步首次超过 1500，最高为 3180.66（435,000 步）；最后 10 次评估的均值为 2388.97，而单 Q 为 770.29。本次运行中 clipped double-Q 明显更好。



图 7. Hopper 的评估回报及平均 Q 值、目标值。

单 Q 的自举目标容易受到价值高估影响；clipped double-Q 取两个目标 Critic 的较小值，减少单个 Critic 的乐观误差进入目标值的机会。图中的 Q 值来自各自策略访问的不同状态和动作，不能仅凭原始 Q 值大小直接量化高估偏差。本实验对“缓解高估有助于训练”的解释提供了支持，但单个训练 seed 不构成严格因果证明。

原始日志、模型参数和运行配置位于 exp/ 中的七组正式实验目录；额外学习率实验用于图 4，详细统计见 report_assets/。报告中的最高分均指训练期间记录的评估均值，最终 checkpoint 未另行作为最高分评估。